



Facultad de Ingeniería
Ingeniería en Ciencia de los Datos

Predicción de resultados del Mundial FIFA 2026

Análisis comparativo mediante modelos estadísticos
y aprendizaje automático con simulación de Monte Carlo

Modelos Cuantitativos de Información – Sección 10

Marco Antonio Carbajal Bonilla

Carné 23025



Guatemala, 31 de mayo de 2026

Resumen

Se presenta un sistema de predicción probabilística de resultados de fútbol internacional aplicado al Mundial FIFA 2026, que responde la pregunta de investigación: *¿aporta el aprendizaje automático una mejora real sobre los modelos estadísticos clásicos en predicciones de fútbol?* Se construyó una base de datos de 23 086 partidos internacionales (2002–2026) enriquecida con un ETL propio sobre la API interna de la FIFA para completar la serie de ranking hasta 2026. Sobre esa base se calcularon variables derivadas (rating Elo, forma reciente y diferencias de ranking) y se compararon cuatro modelos mediante validación temporal en los Mundiales 2010–2022: un baseline de ranking FIFA, el modelo de Poisson independiente (Maher, 1982), Dixon-Coles (Dixon and Coles, 1997) con ponderación temporal y el método de gradient boosting XGBoost (Chen and Guestrin, 2016). En términos de log-loss promedio, Dixon-Coles obtuvo el mejor desempeño (0.975) seguido del baseline (0.985) y de XGBoost (1.005), que no superó al baseline trivial. La respuesta a la pregunta de investigación es negativa para este contexto: las correcciones estadísticas de Dixon-Coles superan al aprendizaje automático. Mediante 20 000 simulaciones de Monte Carlo, el modelo arroja a Argentina como favorita al título (16.9 %), seguida de España (15.4 %) y Brasil (10.1 %). Las quinielas derivadas del modelo coinciden en señalar a Argentina como campeona mundial para la edición del 2026.

Palabras clave: predicción de fútbol; Dixon-Coles; XGBoost; Elo; quiniela; simulación Monte Carlo; Mundial FIFA 2026.

Índice

1. Introducción	4
2. Datos y preparación	5
2.1. Fuentes de datos	5
2.2. ETL del ranking FIFA extendido	5
2.3. Análisis exploratorio	6
2.4. Ventana temporal y unión sin fuga de datos	9
3. Metodología	10
3.1. Variables predictoras	10
3.1.1. Rating Elo	10
3.1.2. Forma reciente y otras variables	12
3.2. Modelos de predicción	12
3.2.1. Baseline de ranking FIFA	12
3.2.2. Poisson independiente (Maher, 1982)	12
3.2.3. Dixon-Coles (Dixon and Coles, 1997)	12
3.2.4. XGBoost multinomial (Chen and Guestrin, 2016)	13
3.3. Esquema de validación temporal	14
3.4. Calibración	14
3.5. Simulación Monte Carlo del Mundial 2026	14
4. Resultados del modelado	16
4.1. Comparación de modelos	16
4.2. Calibración de probabilidades	17
4.3. Fuerza estimada de los participantes	17
4.4. Probabilidades de avance en el Mundial 2026	18
5. Quinielas del Mundial 2026	22
5.1. Quiniela de marcadores modales (Alternativa 1)	22
5.1.1. Fase de grupos	22
5.1.2. Fase de eliminación	24
5.2. Bracket probabilístico (Alternativa 2)	25
5.3. Convergencia de ambas quinielas	27
6. Discusión	28
7. Conclusiones	29
A. Anexos	31
A.1. Descripción de los notebooks	31
A.2. Repositorio del proyecto	31

1. Introducción

El Mundial FIFA 2026, organizado conjuntamente por Estados Unidos, Canadá y México, estrenará un formato de 48 selecciones distribuidas en doce grupos de cuatro equipos, con un total de 104 partidos. La predicción de sus resultados tiene relevancia práctica en los mercados de pronósticos deportivos (cuya facturación global supera los 200 000 millones de dólares anuales) y es, a la vez, un banco de pruebas clásico para comparar metodologías cuantitativas (Groll et al., 2019; Hvattum and Arntzen, 2010).

En el plano académico, la predicción de partidos de fútbol mediante modelos estadísticos tiene más de cuatro décadas de historia. Maher (1982) formalizó la distribución Poisson como modelo de goles; Dixon and Coles (1997) añadieron la corrección de dependencia en marcadores bajos y la ponderación temporal; y trabajos más recientes han incorporado aprendizaje automático con resultados mixtos. La pregunta de si las técnicas de *machine learning* (ML) mejoran sobre los modelos clásicos permanece abierta y depende del contexto particular, en especial del tamaño y la calidad del conjunto de datos disponible.

Pregunta de investigación

¿Aporta el aprendizaje automático una mejora real sobre los modelos estadísticos clásicos en la predicción de resultados del fútbol internacional de alta competición?

Motivación

El proyecto nace de un interés personal: la elaboración de una quiniela fundamentada para el Mundial 2026. Ese objetivo práctico se amplió hacia una comparación metodológica rigurosa al verificar que el historial de resultados y el ranking FIFA, de acceso público, no alcanzaban el año 2026, lo que motivó un proceso de extracción de datos propio.

Contribuciones principales

1. **ETL del ranking FIFA extendido.** Construcción de una serie temporal continua del ranking FIFA hasta abril de 2026 mediante ingeniería inversa de la API interna de la FIFA, cubriendo el período que no está disponible en datasets públicos.
2. **Análisis comparativo bajo validación temporal estricta.** Evaluación de cuatro modelos sobre cuatro pliegues de los Mundiales 2010, 2014, 2018 y 2022, con métricas probabilísticas (log-loss y Brier score).
3. **Simulación del torneo.** 20 000 simulaciones Monte Carlo del Mundial 2026 con el mejor modelo, que producen distribuciones completas de avance y dos versiones de quiniela: una de marcadores modales y una probabilística.

Estructura del informe

La sección 2 describe los datos y el proceso ETL. La sección 3 presenta la metodología en detalle. La sección 4 reporta los resultados del modelado. La sección 5 presenta las quinielas completas del torneo. La sección 6 discute sus implicaciones y la sección 7 cierra con las conclusiones.

2. Datos y preparación

2.1. Fuentes de datos

El proyecto combina tres datasets:

- `results.csv` (Jürisöö, 2026): 49 215 partidos internacionales desde 1872 hasta marzo de 2026 con marcador, sede y torneo. Es la fuente principal para entrenar y validar los modelos.
- `shootouts.csv` (Jürisöö, 2026): 675 registros de partidos decididos por tanda de penales, con el ganador real. Se usa para calibrar el submodelo de penales de la simulación.
- `fifa_ranking_historico.csv` (cashncarry, 2024; Fédération Internationale de Football Association, 2026): serie histórica del ranking FIFA desde diciembre de 1992, extendida hasta abril de 2026 mediante ETL propio (ver § 2.2).

2.2. ETL del ranking FIFA extendido

El dataset público de ranking FIFA disponible en Kaggle (cashncarry, 2024) cubría hasta mediados de 2024. Para disponer de variables de fuerza actualizadas para el torneo de 2026 se desarrolló un proceso ETL propio en cuatro etapas:

1. **Extracción.** El portal de la FIFA es una SPA (*single-page application*) con carga dinámica por JavaScript. Mediante interceptación de las peticiones Fetch/XHR del cliente web se identificaron los *endpoints* de la API interna de la FIFA y se obtuvieron las publicaciones de ranking faltantes en formato JSON estructurado.
2. **Transformación.** Un script en Python extrae los nodos anidados de cada archivo JSON y los mapea a la estructura tabular del dataset histórico: `rank`, `country_full`, `country_abrv`, `total_points`, `previous_points`, `rank_change`, `confederation`.
3. **Normalización temporal.** La fecha de publicación (`rank_date`) se deriva del nombre de cada archivo y se estandariza como objeto `datetime`.
4. **Consolidación y control de calidad.** Los tramos se concatenan y se ordenan cronológicamente; se verifican cuatro condiciones: continuidad temporal (sin huecos anómalos), estabilidad de la escala de puntos, ausencia de duplicados y padrón de selecciones estable.

El dataset final (`fifa_ranking_historico.csv`) contiene 346 publicaciones para 211 selecciones entre 1992 y 2026, con una separación mediana de 28 días entre publicaciones. La Figura 1

muestra que la media y el rango de puntos son continuos en el punto de empalme (junio 2024), confirmando que los dos tramos usan la misma metodología de puntuación.




Figura 1: Control de calidad del empalme del ranking FIFA. La línea roja vertical señala el límite entre el tramo público (izquierda) y el tramo obtenido por ETL propio (derecha). La estabilidad de la media y el rango de puntos confirma la continuidad del dataset. *Fuente:* `Fase1_datos.ipynb`, § 3.4.

2.3. Análisis exploratorio

Composición del dataset

La ventana de modelado comprende 23 086 partidos disputados entre 2002 y 2026, con más de 310 selecciones distintas distribuidas en 113 tipos de torneo. El 66.7 % de los encuentros son partidos oficiales (todo torneo distinto de un amistoso) y el 29 % se disputa en cancha neutral. Esta diversidad de contextos de juego es relevante porque la ventaja de local y el nivel de compromiso competitivo difieren según el tipo de partido.

Distribución de goles

La Figura 2 muestra la distribución de goles por equipo y por partido sobre la ventana de modelado. Las distribuciones del local y del visitante presentan la forma asimétrica característica de la distribución Poisson, con medias de 1.76 y 1.18 goles respectivamente, lo que sustenta el supuesto de Maher (1982) y motiva el uso de modelos de conteo.




Figura 2: Distribución de goles por equipo (local, visitante) y totales en los 23 086 partidos de la ventana de modelado (2002–2026). La forma asimétrica es consistente con el supuesto Poisson. *Fuente:* `Fase1_datos.ipynb`, § 4.2.

Distribución de resultados y ventaja de local

La Figura 3 desglosa la distribución de resultados y el efecto de la neutralidad del campo. En cancha no neutral, el local gana en el 51 % de los encuentros; en cancha neutral ese porcentaje cae al 44 %, prácticamente equiparándose con el visitante. La diferencia de ≈ 7 puntos porcentuales justifica modelar la localía como parámetro explícito y controlar por la variable **neutral**. Este hallazgo es especialmente relevante para el torneo 2026, cuyo formato de 48 selecciones implica que la gran mayoría de equipos participantes compiten en sedes efectivamente neutrales.




Figura 3: Izquierda: distribución global de resultados (victoria local, empate, victoria visitante) en el histórico de partidos internacionales. Derecha: la misma distribución desglosada por neutralidad del campo. La ventaja de local (≈ 7 pp) se diluye completamente en cancha neutral. *Fuente:* Fase1_datos.ipynb, § 4.3.

Perfiles ofensivos por confederación y empates

La Figura 4 revela dos patrones relevantes para el modelado. El panel izquierdo muestra que los perfiles ofensivos difieren por región: las selecciones de CONMEBOL y UEFA producen en promedio más goles como local que las de AFC, CAF u OFC, lo que justifica incluir la confederación como variable predictora en lugar de asumir homogeneidad global. El panel derecho muestra que los partidos oficiales empatan con mayor frecuencia ≈ 25 % que los amistosos (≈ 20 %): el mayor compromiso competitivo favorece planteamientos más cautelosos. Este hallazgo anticipa la discusión de calibración de la sección 4.2, donde se observa que los modelos de goles tienden a sobreestimar la probabilidad de empate.




Figura 4: Izquierda: goles del local por confederación (media sobre la ventana 2002–2026). CONMEBOL y UEFA lideran en producción ofensiva. Derecha: proporción de empates en partidos amistosos frente a oficiales. Los partidos oficiales empatan con mayor frecuencia, lo que es relevante para la calibración de los modelos. *Fuente:* Fase1_datos.ipynb, § 11.1–11.2.

Tendencia temporal y diferencia de ranking

La Figura 5 combina dos análisis que fundamentan decisiones clave de modelado. El panel izquierdo muestra que el promedio de goles por partido ha fluctuado a lo largo de la ventana 2002–2026 con variaciones visibles en el promedio móvil: los parámetros de ataque y defensa no son estacionarios. Esto motiva la ponderación temporal exponencial de Dixon-Coles (ecuación 5): si el nivel de juego cambia con el tiempo, los partidos recientes deben pesar más en la estimación. El panel derecho muestra la distribución de la diferencia de ranking FIFA entre local y visitante ($\Delta\text{rank} = \text{rank}_{\text{local}} - \text{rank}_{\text{visitante}}$). La distribución es aproximadamente simétrica con mediana ≈ 3 y colas largas que abarcan el rango completo del ranking, evidenciando tanto partidos muy equilibrados como encuentros de alta disparidad, lo que dota al modelo de señal predictiva diferenciada.




Figura 5: Izquierda: promedio mensual de goles totales por partido (2002–2026) con promedio móvil de 12 meses en rojo. Las fluctuaciones temporales motivan la ponderación exponencial de Dixon-Coles. Derecha: distribución de la diferencia de ranking FIFA (local – visitante). La distribución es aproximadamente simétrica con mediana ≈ 3 , sin sesgo estructural de emparejamiento. *Fuente:* Fase1_datos.ipynb, § 11.3–11.4.

Poder predictivo del rating Elo

Antes de incorporarlo como variable, conviene verificar empíricamente que el Elo separa los tres posibles resultados. La Figura 6 muestra este análisis sobre la ventana de modelado. El panel izquierdo evidencia que la diferencia de Elo ($\text{elo_diff} = \text{Elo local} - \text{Elo visitante}$) es sistemáticamente mayor en las victorias locales que en las visitantes, con el empate en posición intermedia. El panel derecho confirma la relación monótonica: la tasa de victoria local crece de forma continua a medida que el Elo del local supera al del visitante, superando el 70 % en el decil más favorable. Ambos resultados validan el poder predictivo del Elo y respaldan su uso como medida de fuerza relativa en todos los modelos del proyecto.




Figura 6: Izquierda: distribución de la diferencia de Elo (`elo_diff`) según el resultado del partido (sin valores atípicos). El Elo separa con claridad los tres resultados. Derecha: tasa de victoria local por decil de `elo_diff`; la relación es monótona creciente, lo que confirma el poder predictivo del Elo. *Fuente:* `Fase2_features.ipynb`, § 10.2–10.3.

2.4. Ventana temporal y unión sin fuga de datos

Ventana

Se trabaja con partidos desde el año 2002, lo que produce 23 086 encuentros (66.7 % oficiales). La elección de 2002 en lugar de 2006 obedece al esquema de validación: el primer pliegue (Mundial 2010) necesita 8 años de historia (2002–2010) para estimar con solidez los parámetros de ataque y defensa de ~ 200 selecciones; con inicio en 2006, ese primer pliegue tendría solo cuatro años de calentamiento.

Unión sin fuga

Para cada partido se asigna el ranking FIFA más reciente con fecha *estrictamente anterior o igual* a la del partido, usando `pd.merge_asof` con dirección `backward`. Una publicación del ranking en el día D resume resultados de días anteriores y no incorpora partidos del propio día D , por lo que las coincidencias exactas de fecha no constituyen fuga de datos. El 93 % de los partidos de la ventana dispone de ranking para ambos equipos; el 7 % restante corresponde exclusivamente a territorios no miembros de la FIFA (Martinica, Guadalupe, Zanzibar, etc.) que no participarán en el Mundial 2026.

3. Metodología

3.1. Variables predictoras

3.1.1. Rating Elo

El rating Elo (Elo, 1978), en su variante para fútbol de selecciones (Hvattum and Arntzen, 2010), resume la fuerza de un equipo en un único número actualizado tras cada partido. La regla de actualización es

$$R_i^{(t+1)} = R_i^{(t)} + K \cdot G \cdot (W - W_e), \quad (1)$$

donde $W \in \{0, 0.5, 1\}$ es el resultado real del equipo i (derrota/empate/victoria), y el resultado esperado W_e se calcula como

$$W_e = \frac{1}{1 + 10^{-\Delta r/400}}, \quad \Delta r = (R_{\text{local}} + \text{HFA}) - R_{\text{visitante}}, \quad (2)$$

con ventaja de local $\text{HFA} = 100$ puntos (anulada en cancha neutral). El factor K depende de la importancia del torneo ($K = 60$ para el Mundial; 50, 40, 30 y 20 para continental, clasificatorio, otro y amistoso, respectivamente) y G amplifica la actualización en goleadas según la diferencia de goles d :

$$G = \begin{cases} 1.0 & d \leq 1 \\ 1.5 & d = 2 \\ (11 + d)/8 & d \geq 3 \end{cases}$$

El Elo se calcula sobre el histórico completo (1872–2026) para evitar el problema de arranque en frío: el valor *antes* de la actualización de cada partido (`home_elo_pre`, `away_elo_pre`) se registra como feature, y la actualización solo afecta a partidos posteriores, garantizando la ausencia de fuga de datos.

La Figura 7 ilustra la trayectoria del Elo para seis selecciones de referencia desde 1995, y la Figura 8 verifica la coherencia del Elo comparando el resultado esperado (ecuación 2) con el resultado medio real observado sobre la ventana 2002–2026.




Figura 7: Trayectoria del rating Elo para seis selecciones (1995 en adelante). Se aprecian el ascenso de España en la era 2008–2012, la consolidación de Argentina y las fluctuaciones de Alemania. *Fuente:* Fase2_features.ipynb, § 4.3.




Figura 8: Resultado esperado por el Elo frente al resultado medio observado (local), agrupado por decil. La proximidad a la diagonal confirma que el Elo es un predictor bien calibrado de la *expectativa* del local. *Fuente:* Fase2_features.ipynb, § 4.3.

3.1.2. Forma reciente y otras variables

Para cada equipo y cada partido se calculan promedios móviles sobre los N partidos previos ($N \in \{5, 10\}$) de goles anotados, goles recibidos y puntos, aplicando un `shift(1)` que excluye el partido en curso. Se añaden además la diferencia de días de descanso (capada a 365) y la experiencia acumulada (`matches_prior`). Las diferencias de ranking y de puntos FIFA se heredan de la unión de la sección anterior. El conjunto de features suma 46 variables (32 numéricas + 14 *one-hot* de confederación).

3.2. Modelos de predicción

Los cuatro modelos predicen la distribución de probabilidad sobre tres clases: victoria local (H), empate (D) y victoria visitante (A).

3.2.1. Baseline de ranking FIFA

El baseline asigna la fracción de victorias históricamente obtenida por el mejor clasificado (estimada en entrenamiento), y la fracción de empates observada; cuando el ranking no está disponible reparte equitativamente entre H y A. Es un comparador informativo porque usa el ranking FIFA, un predictor real, y emite probabilidades calibradas.

3.2.2. Poisson independiente (Maher, 1982)

Los goles del local y del visitante se modelan como variables Poisson independientes con medias

$$\log \lambda_h = c + a_h + d_a + \gamma \mathbf{1}_{\text{local}}, \quad \log \mu_a = c + a_a + d_h, \quad (3)$$

donde a_i y d_i son los parámetros de ataque y defensa del equipo i , c es un intercepto común y γ es la ventaja de local ($\gamma = 0$ en cancha neutral). Los parámetros se estiman por máxima verosimilitud como GLM de Poisson. Las selecciones con menos de 10 partidos en la ventana de entrenamiento se agrupan en una categoría *Other* para estabilizar la estimación.

3.2.3. Dixon-Coles (Dixon and Coles, 1997)

Dixon-Coles extiende el Poisson con dos correcciones:

(a) Corrección de marcadores bajos

El Poisson independiente subestima sistemáticamente los resultados 0-0, 1-0, 0-1 y 1-1. Se introduce un factor de ajuste

$$\tau(x, y, \lambda, \mu, \rho) = \begin{cases} 1 - \lambda\mu\rho & x = y = 0 \\ 1 + \lambda\rho & x = 0, y = 1 \\ 1 + \mu\rho & x = 1, y = 0 \\ 1 - \rho & x = y = 1 \\ 1 & \text{en otro caso,} \end{cases} \quad (4)$$

donde $\rho < 0$ incrementa la masa de empates y resultados ajustados en detrimento de los marcadores 1-0 y 0-1.

(b) Ponderación temporal

Cada partido recibe un peso que decae exponencialmente con su antigüedad,

$$w_k = \exp\left(-\frac{\ln 2}{t_{1/2}} (T - t_k)\right), \quad (5)$$

con vida media $t_{1/2} = 730$ días (dos años), de modo que el desempeño reciente pesa más en la estimación.

La log-verosimilitud ponderada es

$$\ell(\theta) = \sum_k w_k \left[\log P(x_k | \lambda_k) + \log P(y_k | \mu_k) + \log \tau(x_k, y_k, \lambda_k, \mu_k, \rho) \right], \quad (6)$$

maximizada mediante L-BFGS-B con gradiente analítico (el gradiente numérico no converge con más de 400 parámetros en un tiempo razonable). La corrección del gradiente se verifica con `scipy.optimize.check_grad`, obteniendo un error de 8.1×10^{-4} , dentro del umbral aceptable.

3.2.4. XGBoost multinomial (Chen and Guestrin, 2016)

XGBoost predice directamente la distribución sobre las tres clases a partir del vector de features de la sección 3.1, capturando interacciones no lineales que los modelos de goles no representan. Se usan hiperparámetros conservadores fijados a priori, sin búsqueda sobre los pliegues de validación, para que las métricas de validación constituyan una estimación honesta. Los valores NaN se pasan tal cual; XGBoost los gestiona de forma nativa aprendiendo la mejor dirección de ramificación para los valores ausentes.

3.3. Esquema de validación temporal

La validación es temporal y expansiva sobre cuatro pliegues. Para el Mundial del año Y , el modelo se entrena con todos los partidos anteriores a su primer encuentro y se valida sobre los 64 partidos de ese torneo:

Pliegue	Entrenamiento	Corte	Validación
1	Partidos anteriores a jun. 2010	2010-06-11	Mundial 2010 (64 partidos)
2	Partidos anteriores a jun. 2014	2014-06-12	Mundial 2014 (64 partidos)
3	Partidos anteriores a jun. 2018	2018-06-14	Mundial 2018 (64 partidos)
4	Partidos anteriores a nov. 2022	2022-11-20	Mundial 2022 (64 partidos)

Las métricas se promedian sobre los cuatro pliegues. Se reporta también la desviación estándar entre pliegues como indicador de estabilidad. Las métricas principales son el log-loss y el Brier score multiclase (Brier, 1950; Gneiting and Raftery, 2007): ambas son *reglas de puntuación estrictamente propias*, es decir, se optimizan únicamente prediciendo la distribución de probabilidad verdadera. La predicción uniforme $(1/3, 1/3, 1/3)$ produce un log-loss de referencia de $\ln 3 \approx 1.099$.

3.4. Calibración

Más allá de la discriminación (qué modelo ordena mejor los resultados), la calibración determina si las probabilidades emitidas son coherentes con la frecuencia real: cuando un modelo asigna 70 % a un evento, ese evento debería ocurrir aproximadamente el 70 % de las veces. La calibración se evalúa mediante diagramas de fiabilidad por clase contruidos sobre las 256 predicciones fuera de muestra de los cuatro pliegues.

Se intentó corregir la descalibración detectada con una recalibración logística multinomial (variante de la calibración de Platt para tres clases), evaluada con un esquema *leave-one-fold-out* para evitar fuga de datos.

3.5. Simulación Monte Carlo del Mundial 2026

Se realizaron 20 000 simulaciones completas del torneo con semilla fija ($SEED = 42$) usando el modelo Dixon-Coles ajustado sobre todos los partidos disponibles hasta abril de 2026. Cada simulación:

1. Simula los doce grupos de cuatro equipos; los dos primeros de cada grupo más los ocho mejores terceros avanzan a dieciseisavos.
2. Resuelve la fase de eliminación directa (dieciseisavos, octavos, cuartos, semifinales, tercer

puesto y final) mediante sorteos de la distribución conjunta de marcadores.

3. Resuelve los empates de la fase eliminatoria mediante un sorteo de tiempo extra y, si persiste el empate, mediante un sorteo de penales.

Submodelo de penales

Los 378 partidos decididos por penales en la ventana 2002–2026 evidencian que el favorito Elo gana la tanda con una frecuencia de 55 % ($P_{\text{pen}} = 0.55$). Este valor se usa como probabilidad de avance para el equipo con mayor rating Elo cuando el partido llega a la tanda.

Construcción de quinielas

Se construyen dos versiones de quiniela determinista a partir del modelo:

- *Alternativa 1 (marcadores modales)*: el marcador de cada partido es el modo de la distribución conjunta Dixon-Coles, es decir, la celda (x, y) de máxima probabilidad de la matriz de marcadores. Esta quiniela predice un resultado concreto para cada uno de los 104 partidos del torneo.
- *Alternativa 2 (bracket probabilístico)*: en la fase eliminatoria no se predicen marcadores sino probabilidades de avance. El equipo que avanza es el de mayor $P(\text{avance})$, donde

$$P(\text{avance}_a) = P(\text{victoria}_a^{90'}) + P(\text{empate}) \times P(\text{penales}_a \mid \text{favorito}), \quad (7)$$

mostrando explícitamente la incertidumbre en lugar de ocultarla.

Las quinielas completas se presentan en la sección 5.

4. Resultados del modelado

4.1. Comparación de modelos

La Tabla 1 muestra las tres métricas promediadas sobre los cuatro pliegues de validación temporal.

Tabla 1: Métricas de evaluación promediadas sobre los cuatro Mundiales de validación (2010, 2014, 2018, 2022). Se muestran media y desviación estándar entre pliegues. Menor es mejor para log-loss y Brier; mayor es mejor para accuracy. El mejor valor de cada columna se marca en **negrita**. Log-loss de referencia (predicción uniforme): 1.099.

Modelo	Log-loss (media $\pm$ d.e.)	Brier (media $\pm$ d.e.)	Accuracy (media)
Baseline (ranking FIFA)	0.985 $\pm$ 0.049	0.586 $\pm$ –	0.566
Poisson independiente	0.990 $\pm$ 0.015	0.589 $\pm$ –	0.547
Dixon-Coles	0.975 $\pm$ 0.044	0.576 $\pm$ –	0.563
XGBoost	1.005 $\pm$ 0.057	0.592 $\pm$ –	0.527

La Tabla 2 desglosa el log-loss por pliegue, mostrando la variabilidad entre torneos.

Tabla 2: Log-loss por Mundial (pliegue de validación). El mejor valor de cada columna se marca en **negrita**.

Modelo	2010	2014	2018	2022	Media	D.E.
Baseline	1.001	0.918	1.034	0.988	0.985	0.049
Poisson	0.981	1.010	0.975	0.993	0.990	0.015
Dixon-Coles	0.954	0.954	0.951	1.042	0.975	0.044
XGBoost	1.020	0.936	0.992	1.072	1.005	0.057

La Figura 9 muestra la evolución de las tres métricas a lo largo de los cuatro pliegues.




Figura 9: Comparación de log-loss, Brier score y accuracy por pliegue de validación para los cuatro modelos. La línea de puntos gris en el panel izquierdo es el log-loss de la predicción uniforme ($\ln 3 \approx 1.099$). Todos los modelos superan este umbral. *Fuente:* `Fase3_modelado.ipynb`, § 10.3.

4.2. Calibración de probabilidades

Los diagramas de fiabilidad (Figura 10) revelan que los dos modelos de goles sobreestiman la probabilidad de empate: Poisson asigna en promedio 28.0 % y Dixon-Coles 27.7 %, mientras que la frecuencia real de empate en los cuatro Mundiales de validación fue del 22.3 %. El baseline (23.5 %) y XGBoost (24.0 %) se acercan más a lo observado.




Figura 10: Diagramas de fiabilidad para la clase empate, antes y después de recalibración logística multinomial (*leave-one-fold-out*). La línea discontinua gris es la diagonal de calibración perfecta. *Fuente:* Fase3_modelado.ipynb, § 12.

La recalibración logística multinomial, evaluada sin fuga mediante esquema *leave-one-fold-out*, no mejora el desempeño: empeora el log-loss de los cuatro modelos, en especial de Dixon-Coles (+0.031) y XGBoost (+0.018). La causa probable es el reducido número de pliegues disponibles (cuatro Mundiales): con solo ~ 192 predicciones de entrenamiento para el recalibrador y alta heterogeneidad entre torneos, la corrección aprendida no transfiere bien a un Mundial no visto.

4.3. Fuerza estimada de los participantes

La Figura 11 muestra el índice de fuerza neta de los 48 participantes del Mundial 2026 según Dixon-Coles, definido como la suma del parámetro de ataque y el negativo del parámetro de defensa (un valor positivo indica un equipo que anota mucho y recibe poco). Esto constituye una prueba de consistencia y robustez del modelo antes de ejecutar la simulación.




Figura 11: Índice de fuerza neta estimada por Dixon-Coles para los 48 participantes del Mundial 2026 (escala logarítmica de goles). Verde: fuerza positiva; rojo: fuerza negativa respecto al promedio.
Fuente: Fase4_simulacion.ipynb, § 3.1.

El ranking de fuerza del modelo coincide en sus primeras posiciones con la jerarquía futbolística esperada (Argentina, España, Brasil, Francia).

4.4. Probabilidades de avance en el Mundial 2026

La Tabla 3 presenta las probabilidades de alcanzar cada fase para las veinte selecciones más favoritas, obtenidas como frecuencias relativas en las 20 000 simulaciones.

Tabla 3: Probabilidad (%) de alcanzar cada fase del Mundial 2026 para las 20 selecciones más probables campeonas. Las cinco primeras concentran el 58.5 % de la probabilidad total de título. Ordenado por P(campeón). Ranking FIFA a abril de 2026.

Selección	Gr.	Oct.	4.tos	Semi	Final	Camp.	Rank.
Argentina	98.2	68.3	54.0	38.8	25.8	16.9	3
España	99.1	68.9	48.9	36.7	25.0	15.4	2
Brasil	98.7	68.7	48.4	31.8	17.9	10.1	6
Inglaterra	97.9	67.9	45.1	27.2	15.3	8.6	4
Francia	94.4	67.3	43.3	26.3	14.5	7.5	1
Portugal	92.6	65.2	40.8	23.6	13.1	6.9	5
Colombia	90.5	60.1	35.1	19.2	10.4	4.8	13
Países Bajos	88.9	48.2	32.2	17.5	8.5	3.8	7
Marruecos	93.3	52.7	33.2	17.9	8.5	3.8	8
Alemania	98.0	67.3	34.6	18.1	8.1	3.6	10
Bélgica	93.1	60.2	33.4	14.0	6.5	2.5	9
Japón	81.2	39.0	22.6	10.6	4.4	1.8	18
Ecuador	92.9	54.1	24.9	11.6	4.7	1.8	23
Suiza	96.7	62.3	28.0	11.6	4.8	1.8	19
Uruguay	89.3	38.7	22.3	10.3	4.6	1.7	17
Croacia	91.4	47.2	22.2	10.2	4.3	1.7	11
Noruega	82.8	47.4	24.1	10.4	4.3	1.6	31
Senegal	78.9	42.7	20.7	8.8	3.5	1.3	14
Austria	79.1	31.1	15.3	6.4	2.6	0.9	24
Argelia	72.3	25.1	10.9	3.9	1.3	0.4	28

Las Figuras 12 y 13 ilustran, respectivamente, el ranking de probabilidades de título y el perfil de avance por fase de las doce selecciones más favoritas.




Figura 12: Probabilidad de ganar el Mundial 2026 para las 16 selecciones más probables. Argentina lidera con el 16.9 %, seguida de España (15.4 %) y Brasil (10.1 %). El ranking no sigue estrictamente al ranking FIFA: Francia (1.^a del mundo) cae al 5.^o lugar en probabilidad de título. *Fuente:* Fase4_simulacion.ipynb, § 9.




Figura 13: Perfil de avance por fase para las 12 selecciones más favoritas. Las curvas muestran cómo se va reduciendo la probabilidad de avance en cada ronda. *Fuente:* Fase4_simulacion.ipynb, § 9.

Un resultado notable es que la selección mejor ubicada en el ranking FIFA (Francia, 1.^a) cae al 5.^o puesto en probabilidad de campeonato. Esto refleja tanto la fortaleza del modelo para Argentina (parámetros de ataque y defensa históricamente altos) como la alta paridad entre las selecciones de élite.

La Figura 14 compara la probabilidad de alcanzar cuartos de final con el ranking FIFA, identificando candidatas a sorpresa.




Figura 14: Probabilidad de alcanzar cuartos de final frente al ranking FIFA. Las selecciones anotadas fuera del top 16 del ranking con mayor $P(\text{cuartos})$ son candidatas a sorpresa: Noruega, Ecuador, Suiza y Japón. *Fuente:* Fase4_simulacion.ipynb, § 10.

5. Quinielas del Mundial 2026

A partir del modelo Dixon-Coles calibrado se construyeron dos quinielas deterministas para los 104 partidos del torneo. La Alternativa 1 predice el marcador más probable de cada partido (modo de la distribución conjunta); la Alternativa 2 reemplaza los marcadores de la fase eliminatoria por probabilidades de avance explícitas. Ambas comparten idéntica fase de grupos y convergen en el mismo campeón: Argentina.

5.1. Quiniela de marcadores modales (Alternativa 1)

5.1.1. Fase de grupos

Las tablas a continuación muestran los resultados por jornada y las posiciones finales de los doce grupos. El símbolo (*) indica clasificación directa como primero o segundo; (†) indica clasificación como mejor tercero.

Grupo A

J1: MEX 1–0 RSA; KOR 1–1 CZE

J2: MEX 1–1 KOR; RSA 0–1 CZE

J3: MEX 1–1 CZE; RSA 0–1 KOR

	Selección	G	E	P	GF	GC	Pts
1	México*	1	2	0	3	2	5
2	Corea del Sur*	1	2	0	3	2	5
3	Chequia†	1	2	0	3	2	5
4	Sudáfrica	0	0	3	0	3	0

Grupo C

J1: BRA 0–0 MAR; HAI 0–2 SCO

J2: BRA 3–0 HAI; MAR 1–0 SCO

J3: BRA 2–0 SCO; MAR 2–0 HAI

	Selección	G	E	P	GF	GC	Pts
1	Brasil*	2	1	0	5	0	7
2	Marruecos*	2	1	0	3	0	7
3	Escocia†	1	0	2	2	3	3
4	Haití	0	0	3	0	7	0

Grupo B

J1: CAN 1–0 BIH; QAT 0–2 SUI

J2: CAN 1–0 QAT; BIH 0–2 SUI

J3: CAN 0–1 SUI; BIH 1–1 QAT

	Selección	G	E	P	GF	GC	Pts
1	Suiza*	3	0	0	5	0	9
2	Canadá*	2	0	1	2	1	6
3	Catar	0	1	2	1	4	1
4	Bosnia y Herz.	0	1	2	1	4	1

Grupo D

J1: USA 1–1 PAR; AUS 1–1 TUR

J2: USA 1–1 AUS; PAR 1–1 TUR

J3: USA 1–1 TUR; PAR 0–0 AUS

	Selección	G	E	P	GF	GC	Pts
1	EE.UU.*	0	3	0	3	3	3
2	Turquía*	0	3	0	3	3	3
3	Australia†	0	3	0	2	2	3
4	Paraguay	0	3	0	2	2	3

Grupo E

J1: GER 3-0 CUW; CIV 0-0 ECU

J2: GER 1-0 CIV; CUW 0-2 ECU

J3: GER 0-0 ECU; CUW 0-2 CIV

	Selección	G	E	P	GF	GC	Pts
1	Alemania*	2	1	0	4	0	7
2	Ecuador*	1	2	0	2	0	5
3	C. de Marfil [†]	1	1	1	2	1	4
4	Curazao	0	0	3	0	7	0

Grupo G

J1: BEL 1-0 EGY; IRN 1-0 NZL

J2: BEL 1-1 IRN; EGY 1-0 NZL

J3: BEL 2-0 NZL; EGY 0-0 IRN

	Selección	G	E	P	GF	GC	Pts
1	Bélgica*	2	1	0	4	1	7
2	Irán*	1	2	0	2	1	5
3	Egipto [†]	1	1	1	1	1	4
4	N. Zelanda	0	0	3	0	4	0

Grupo I

J1: FRA 1-0 SEN; IRQ 0-1 NOR

J2: FRA 2-0 IRQ; SEN 1-1 NOR

J3: FRA 1-1 NOR; SEN 1-0 IRQ

	Selección	G	E	P	GF	GC	Pts
1	Francia*	2	1	0	4	1	7
2	Noruega*	1	2	0	3	2	5
3	Senegal [†]	1	1	1	2	2	4
4	Irak	0	0	3	0	4	0

Grupo K

J1: POR 1-0 COD; UZB 0-1 COL

J2: POR 1-0 UZB; COD 0-1 COL

J3: POR 1-1 COL; COD 0-0 UZB

	Selección	G	E	P	GF	GC	Pts
1	Portugal*	2	1	0	3	1	7
2	Colombia*	2	1	0	3	1	7
3	Congo RD	0	1	2	0	2	1
4	Uzbekistán	0	1	2	0	2	1

Grupo F

J1: NED 1-1 JPN; SWE 1-1 TUN

J2: NED 2-1 SWE; JPN 1-0 TUN

J3: NED 1-0 TUN; JPN 1-1 SWE

	Selección	G	E	P	GF	GC	Pts
1	Países Bajos*	2	1	0	4	2	7
2	Japón*	1	2	0	3	2	5
3	Suecia [†]	0	2	1	3	4	2
4	Túnez	0	1	2	1	3	1

Grupo H

J1: ESP 2-0 CPV; KSA 0-1 URU

J2: ESP 2-0 KSA; CPV 0-1 URU

J3: ESP 1-0 URU; CPV 0-0 KSA

	Selección	G	E	P	GF	GC	Pts
1	España*	3	0	0	5	0	9
2	Uruguay*	2	0	1	2	1	6
3	A. Saudita	0	1	2	0	3	1
4	Cabo Verde	0	1	2	0	3	1

Grupo J

J1: ARG 1-0 ALG; AUT 2-0 JOR

J2: ARG 1-0 AUT; ALG 2-0 JOR

J3: ARG 2-0 JOR; ALG 1-1 AUT

	Selección	G	E	P	GF	GC	Pts
1	Argentina*	3	0	0	4	0	9
2	Austria*	1	1	1	3	2	4
3	Argelia [†]	1	1	1	3	2	4
4	Jordania	0	0	3	0	6	0

Grupo L

J1: ENG 1-0 CRO; GHA 1-1 PAN

J2: ENG 2-0 GHA; CRO 2-0 PAN

J3: ENG 2-0 PAN; CRO 1-0 GHA

	Selección	G	E	P	GF	GC	Pts
1	Inglaterra*	3	0	0	5	0	9
2	Croacia*	2	0	1	3	1	6
3	Ghana	0	1	2	1	4	1
4	Panamá	0	1	2	1	5	1

Mejores terceros clasificados (8 plazas).

De los doce terceros, avanzan los ocho con mejor desempeño combinado (puntos, diferencia de goles y goles a favor):

Grupo	Selección	Pts	DG
A	Chequia	5	+1
J	Argelia	4	+1
E	C. de Marfil	4	+1
I	Senegal	4	0
G	Egipto	4	0
D	Australia	3	0
C	Escocia	3	-1
F	Suecia	2	-1

5.1.2. Fase de eliminación

Los marcadores indicados son los del tiempo reglamentario (90 min). En los empates se señala el equipo clasificado por penales (pen.).

Dieciseisavos de final (partidos 73–88)

Partido	Clasificado
Corea del Sur 1–1 Canadá	Canadá (pen.)
Alemania 2–0 Chequia	Alemania
Países Bajos 0–0 Marruecos	Países Bajos (pen.)
Brasil 1–1 Japón	Brasil (pen.)
Francia 1–0 Escocia	Francia
Ecuador 0–0 Noruega	Ecuador (pen.)
México 0–0 C. de Marfil	México (pen.)
Inglaterra 1–0 Senegal	Inglaterra
EE. UU. 1–1 Suecia	Suecia (pen.)
Bélgica 1–1 Argelia	Bélgica (pen.)
Colombia 1–1 Croacia	Colombia (pen.)
España 1–0 Austria	España
Suiza 1–0 Egipto	Suiza
Argentina 1–0 Uruguay	Argentina
Portugal 1–0 Australia	Portugal
Turquía 1–1 Irán	Turquía (pen.)

Octavos de final (partidos 89–96)

Partido			Clasificado
Alemania	1–1	Francia	Francia (pen.)
Canadá	0–1	Países Bajos	Países Bajos
Brasil	1–0	Ecuador	Brasil
México	0–1	Inglterra	Inglterra
Colombia	1–1	España	España (pen.)
Suecia	1–1	Bélgica	Bélgica (pen.)
Argentina	2–0	Turquía	Argentina
Suiza	1–1	Portugal	Portugal (pen.)

Cuartos de final (partidos 97–100)

Partido			Clasificado
Francia	1–1	Países Bajos	Francia (pen.)
España	1–1	Bélgica	España (pen.)
Brasil	1–1	Inglterra	Brasil (pen.)
Argentina	1–0	Portugal	Argentina

Semifinales (partidos 101–102)

Partido			Clasificado
Francia	1–1	España	España (pen.)
Brasil	0–1	Argentina	Argentina

Tercer puesto (partido 103)		Ganador	Final (partido 104)		Ganador
Francia	1–1	Brasil	España	0–0	Argentina
		Brasil (pen.)			Argentina (pen.)

Campeón Mundial FIFA 2026 (Alternativa 1): Argentina

5.2. Bracket probabilístico (Alternativa 2)

En esta versión la fase de grupos es idéntica a la Alternativa 1. La diferencia está en la fase eliminatoria: en lugar de predecir un marcador concreto, se calcula $P(\text{avance})$ para cada equipo según la ecuación (7) y avanza el equipo con mayor probabilidad. Este formato hace visible la incertidumbre de los cruces reñidos.

Dieciseisavos de final (partidos 73–88)

Equipo A	Equipo B	Clasificado
Corea del Sur (46.1 %)	Canadá (53.9 %)	Canadá
Alemania (74.4 %)	Chequia (25.6 %)	Alemania
Países Bajos (53.1 %)	Marruecos (46.9 %)	Países Bajos
Brasil (64.4 %)	Japón (35.6 %)	Brasil
Francia (78.0 %)	Escocia (22.0 %)	Francia
Ecuador (52.0 %)	Noruega (48.0 %)	Ecuador
México (53.4 %)	C. de Marfil (46.6 %)	México
Inglaterra (65.6 %)	Senegal (34.4 %)	Inglaterra
EE. UU. (43.2 %)	Suecia (56.8 %)	Suecia
Bélgica (62.4 %)	Argelia (37.6 %)	Bélgica
Colombia (60.5 %)	Croacia (39.5 %)	Colombia
España (74.5 %)	Austria (25.5 %)	España
Suiza (65.1 %)	Egipto (34.9 %)	Suiza
Argentina (69.0 %)	Uruguay (31.0 %)	Argentina
Portugal (71.9 %)	Australia (28.1 %)	Portugal
Turquía (52.0 %)	Irán (48.0 %)	Turquía

Octavos de final (partidos 89–96)

Equipo A	Equipo B	Clasificado
Alemania (40.3 %)	Francia (59.7 %)	Francia
Canadá (28.0 %)	Países Bajos (72.0 %)	Países Bajos
Brasil (64.0 %)	Ecuador (36.0 %)	Brasil
México (26.8 %)	Inglaterra (73.2 %)	Inglaterra
Colombia (36.4 %)	España (63.6 %)	España
Suecia (32.6 %)	Bélgica (67.4 %)	Bélgica
Argentina (81.0 %)	Turquía (19.0 %)	Argentina
Suiza (36.1 %)	Portugal (63.9 %)	Portugal

Cuartos de final (partidos 97–100)

Equipo A	Equipo B	Clasificado
Francia (56.9 %)	Países Bajos (43.1 %)	Francia
España (70.1 %)	Bélgica (29.9 %)	España
Brasil (52.4 %)	Inglaterra (47.6 %)	Brasil
Argentina (62.0 %)	Portugal (38.0 %)	Argentina

Semifinales y final			
Ronda	Equipo A	Equipo B	Clasificado
Semifinal (101)	Francia (40.2 %)	España (59.8 %)	España
Semifinal (102)	Brasil (41.2 %)	Argentina (58.8 %)	Argentina
3.er puesto (103)	Francia (45.8 %)	Brasil (54.2 %)	Brasil
Final (104)	España (46.2 %)	Argentina (53.8 %)	Argentina

Campeón Mundial FIFA 2026 (Alternativa 2): Argentina

5.3. Convergencia de ambas quinielas

A pesar de diferir en su filosofía (marcadores fijos frente a probabilidades explícitas), las dos quinielas coinciden en el grueso del bracket. En los octavos de final, los ocho clasificados son idénticos en ambas versiones. En cuartos, también ocho de ocho. El único cruce en que los métodos divergen visiblemente es la semifinal 101 (Francia–España): la Alternativa 1 la resuelve a penales (marcador modal 1–1), mientras que la Alternativa 2 asigna solo el 40.2 % a Francia, reflejando que España es claramente favorita aunque el cruce sea disputado.

La convergencia en el mismo campeón bajo supuestos tan distintos refuerza la predicción: Argentina es la selección que el modelo ve con mayor probabilidad de alzar el título del Mundial FIFA 2026.

6. Discusión

Respuesta a la pregunta de investigación

Los resultados son inequívocos para el contexto de este proyecto: el aprendizaje automático no aporta una mejora sobre los modelos estadísticos clásicos en la predicción del fútbol internacional de alta competición. XGBoost, con 46 features diseñadas a partir de la literatura especializada, no supera al baseline trivial de ranking FIFA en log-loss promedio. Dixon-Coles, un modelo estadístico de 1997, lidera en los cuatro Mundiales de validación excepto 2022.

Tres factores explican este resultado. Primero, el *conjunto de validación es deliberadamente difícil*: 64 partidos entre selecciones de élite con paridad alta, donde las features cuantitativas capturan poca señal diferencial. Segundo, el Poisson y Dixon-Coles *modelan el mecanismo generador de datos* (los goles) mientras que XGBoost optimiza directamente sobre la variable objetivo discreta (el resultado), ignorando la estructura generativa subyacente de conteo de goles que modelos paramétricos como Poisson sí logran capturar. Tercero, *el tamaño de muestra de entrenamiento*, aunque amplio en términos absolutos, es pequeño para XGBoost en comparación con los dominios donde es más exitoso (cientos de miles de observaciones con señal clara).

¿Por qué Dixon-Coles supera al Poisson independiente?

La corrección τ redistribuye masa de probabilidad hacia los marcadores ajustados (0-0 y 1-1), que son los más frecuentes en el fútbol de alta competición. La ponderación temporal asigna mayor influencia a los partidos recientes, lo cual es especialmente relevante dada la rotación frecuente de plantillas nacionales. Ambas mejoras atacan debilidades específicas del Poisson que son prominentes precisamente en el contexto de Mundiales.

El pliegue de 2022

El Mundial de Qatar 2022 estuvo marcado por resultados atípicos y alta varianza en fases tempranas (como la inesperada eliminación de Alemania y Bélgica en fase de grupos, o la caída de España en octavos de final). Aunque los finalistas (Argentina y Francia) terminaron reflejando la jerarquía futbolística histórica, la varianza introducida en los primeros cruces degradó el desempeño de los modelos en este pliegue. En particular, Dixon-Coles, el mejor modelo en los tres pliegues anteriores, obtiene su peor log-loss en 2022 (1.042). Esto refleja una limitación estructural del enfoque frecuentista: cuando la realización del torneo exhibe desviaciones significativas respecto a la distribución histórica esperada, la capacidad predictiva se ve fuertemente penalizada.

Limitaciones

- *Nuevo formato.* El Mundial 2026 estrena el formato de 48 equipos. El modelo entrena sobre datos de torneos de 32 selecciones, por lo que los grupos y los cruces de dieciseisavos de final carecen de precedente histórico directo.
- *Solo cuatro plieques.* Con cuatro Mundiales disponibles como conjunto de validación, las diferencias de log-loss de 0.01–0.02 entre modelos son estadísticamente difíciles de interpretar.
- *Calibración.* Los modelos de goles sobreestiman el empate en partidos de Mundial. La recalibración posterior no se puede aprender con cuatro torneos; esta es la extensión natural más relevante cuando el historial de Mundiales crezca.
- *Lesiones y sanciones.* El modelo usa historial hasta el corte; no incorpora información táctica, lesiones o suspensiones conocidas antes del torneo.

7. Conclusiones

Este trabajo presentó un sistema completo de predicción probabilística para el Mundial FIFA 2026, respondiendo la pregunta de si el aprendizaje automático mejora sobre los modelos estadísticos clásicos en este dominio. La respuesta es negativa: Dixon-Coles (Dixon and Coles, 1997) obtuvo el menor log-loss promedio (0.975) en la validación temporal sobre los Mundiales 2010–2022, superando a XGBoost (1.005) que ni siquiera mejoró al baseline de ranking FIFA (0.985). Las dos correcciones estadísticas de Dixon-Coles (dependencia en marcadores bajos y ponderación temporal exponencial) capturan señal relevante que el gradient boosting no logra recuperar con 46 features en conjuntos de validación de 64 partidos de alta paridad.

La simulación Monte Carlo con 20 000 iteraciones del torneo arroja a Argentina como favorita al título (16.9 %), seguida de España (15.4 %) y Brasil (10.1 %). Las cinco selecciones más probables concentran el 58.5 % de la probabilidad total de campeonato, reflejando una alta concentración en la cima que es consistente con el historial del torneo. Ambas quinielas derivadas del modelo (por marcadores modales y por bracket probabilístico) coinciden en Argentina como campeona, lo que refuerza la robustez de la predicción pese a que la final es ajustada (53.8 % para Argentina frente a 46.2 % para España).

Los resultados son coherentes con la literatura: Hvattum and Arntzen (2010) muestran que el Elo es competitivo frente a métodos complejos; Groll et al. (2019) confirman que los modelos híbridos aportan sobre los estadísticos solo con conjuntos de datos más amplios o features adicionales de información interna de los equipos.

Como trabajo futuro, las líneas más prometedoras son: (1) optimizar la vida media de la ponderación temporal de Dixon-Coles; (2) incorporar variables de alineación y lesiones previas al torneo; y (3) ampliar el análisis a fases de clasificatorias donde el tamaño de muestra de validación es mayor y las diferencias entre modelos son más interpretables.

Referencias

- Brier, G. W. (1950). Verification of forecasts expressed in terms of probability. *Monthly Weather Review*, 78(1):1–3.
- cashncarry (2024). FIFA world ranking 1992–2024. Kaggle. Accedido: mayo 2026.
- Chen, T. and Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794.
- Dixon, M. J. and Coles, S. G. (1997). Modelling association football scores and inefficiencies in the football betting market. *Journal of the Royal Statistical Society: Series C (Applied Statistics)*, 46(2):265–280.
- Elo, A. E. (1978). *The Rating of Chessplayers, Past and Present*. Arco Publishing, New York.
- Fédération Internationale de Football Association (2026). FIFA/Coca-Cola Men’s World Ranking. API interna de la FIFA. Datos obtenidos mediante ingeniería inversa de la API interna; accedido enero–abril 2026.
- Gneiting, T. and Raftery, A. E. (2007). Strictly proper scoring rules, prediction, and estimation. *Journal of the American Statistical Association*, 102(477):359–378.
- Groll, A., Ley, C., Schauburger, G., and Van Eetvelde, H. (2019). A hybrid random forest to predict soccer matches in international tournaments. *Journal of Quantitative Analysis in Sports*, 15(4):271–287.
- Hvattum, L. M. and Arntzen, H. (2010). Using ELO ratings for match result prediction in association football. *International Journal of Forecasting*, 26(3):460–470.
- Jürisöö, M. (2026). International football results from 1872 to 2026. Kaggle. Accedido: mayo 2026.
- Maher, M. J. (1982). Modelling association football scores. *Statistica Neerlandica*, 36(3):109–118.

A. Anexos

A.1. Descripción de los notebooks

El análisis completo está organizado en cuatro Jupyter notebooks en la carpeta `scripts/`, siguiendo el flujo de trabajo del proyecto:

`Fase1_datos.ipynb` Carga, exploración (EDA), control de calidad del empalme del ranking FIFA, decisión de la ventana temporal, limpieza, unión sin fuga de datos con `merge_asof` e integración de los resultados de penales. Entregable: `data_clean.csv` (23 086 partidos, 16 columnas).

`Fase2_features.ipynb` Ingeniería de variables: rating Elo completo sobre el histórico (1872–2026), forma reciente con dos horizontes ($N = 5$ y $N = 10$), días de descanso y experiencia acumulada. Auditoría explícita de fuga de datos. Entregable: `data_features.csv` (23 086 partidos, 44 columnas).

`Fase3_modelado.ipynb` Implementación de los cuatro modelos, validación temporal expansiva sobre los Mundiales 2010–2022, comparación por log-loss y Brier score, diagramas de fiabilidad y análisis de recalibración. Entregables: `resultados_validacion.csv` y `predicciones_oof.csv`.

`Fase4_simulacion.ipynb` Configuración del torneo (grupos, llaves de eliminación), submodelo de penales, 20 000 simulaciones Monte Carlo, tablas de probabilidades de avance y las dos quinielas (marcadores modales y bracket probabilístico). Entregables: `simulacion_grupos.csv` y `simulacion_probabilidades.csv`.

A.2. Repositorio del proyecto

Todos los notebooks, datos de entrada y archivos de resultados están disponibles públicamente en el siguiente repositorio de GitHub:

https://github.com/marcocarbajalb/proyecto_final_MCI

El repositorio se organiza de la siguiente manera:

`proyecto_final_MCI/` (raíz)

Contiene los cuatro notebooks principales del proyecto: `Fase1_datos.ipynb`, `Fase2_features.ipynb`, `Fase3_modelado.ipynb` y `Fase4_simulacion.ipynb`.

`datos/`

Archivos CSV de entrada utilizados por los notebooks: el historial de partidos internacionales (`results.csv`), los registros de tandas de penales (`shootouts.csv`) y la serie histórica del ranking FIFA extendida (`fifa_ranking_historico.csv`).

figuras/

Figuras exportadas automáticamente por los notebooks en formato PDF, correspondientes a todos los gráficos incluidos en este informe.

resultados/

Archivos CSV generados como entregables de cada fase: `data_clean.csv`, `data_features.csv`, `resultados_validacion.csv`, `predicciones_oof.csv`, `simulacion_grupos.csv` y `simulacion_probabilidades.csv`.

scrapping/

Archivos JSON individuales (uno por cada fecha de actualización) con los datos del ranking faltantes obtenidos mediante ingeniería inversa de la API interna de la FIFA, junto con el script de Python (`fifa_scrapper.py`) utilizado para procesarlos, así como el CSV con los datos históricos del ranking (`data_historica.csv`) obtenido de Kaggle.